

説明文書_データ

氏 名	谷川明英
学籍番号	情 22-0291
研 究 室	林貴宏研究室

■ 目的

本資料では，“卒業研究_谷川明英/5 データ” フォルダに格納されている実験データについて説明する。

■ 構造

“5 データ” フォルダの構造は図 1 の通りである。

5 データ

└5-1 予備実験用データ

- | └5-1-1 参考文献文字列（実在）
 - | └doi_list.txt
 - | └positive_reference_ipsj_pre.txt
 - | └positive_reference_jsai_pre.txt
 - | └positive_reference_lsjs_pre.txt
- | └5-1-2 参考文献文字列（架空）
 - | └negative_reference_ipsj_pre.txt
 - | └negative_reference_jsai_pre.txt
 - | └negative_reference_lsjs_pre.txt
- | └5-1-3 論文タイトル一覧
 - | └pre_experiment_titles.txt
 - | └llm_create_titles_2.txt

└5-2 評価実験用データ

- | └5-2-1 参考文献文字列（実在）
 - | └doi_list.txt
 - | └positive_reference_ipsj_eval.txt
 - | └positive_reference_jsai_eval.txt

		positive_reference_lsjeval.txt
		positive_reference_real.txt
		real_reference_doi_list.txt
		5-2-2 参考文献文字列（架空）
		negative_reference_ipsjeval.txt
		negative_reference_jsai_eval.txt
		negative_reference_lsjeval.txt
		negative_reference_real.txt
		5-2-3 論文タイトル一覧
		eval_experiment_titles.txt
		llm_create_titles.txt
		5-3 日本学術会議協力学術研究団体
		scj_registered_AcademicSocieties.txt
		5-4Apache Solr_動作テスト用データ
		jsai_reference_book.txt
		jsai_reference_others.txt
		jsai_reference_paper.txt
		jsai_reference_url.txt
		jsai_reference.txt

図 1. “5 データ” フォルダの構造

■ 説明

“5 データ” フォルダには、予備実験および評価実験でクエリとして使用した参考文献文字列や、それらの作成に用いたものを格納している。ここで、参考文献文字列（実在）とは、データベース (Apache Solr) 登録されている論文を指す参考文献文字列のことであり、参考文献文字列（架空）とは、データベース登録されていない論文を指す参考文献文字列のことである。また、これらの作成方法の詳細については卒業論文を参照されたい。

▼ 5 データ/5-1 予備実験用データ/5-1-1 参考文献文字列（実在）/doi_list.txt

当該ファイルは、予備実験で使用した参考文献文字列（実在）に対する、データベース

上の該当する論文の DOI を各行に記載したテキストファイルである.

▼ 5 データ/5-1 予備実験用データ/5-1-1 参考文献文字列（実在）

/positive_reference_XXXX_pre.txt

当該ファイルは、予備実験で使用した参考文献文字列（実在）を各行に記載したテキストファイルである. なお、テキストファイル名の XXXX に該当する部分には、参考文献文字列（実在）を作成する際に参考にした学会（の引用スタイル）が記述されている.

（表 1 参照）

XXXX	学会
ipsj	情報処理学会
jsai	人工知能学会
lsj	日本言語学会

表 1. 参考にした学会一覧

▼ 5 データ/5-1 予備実験用データ/5-1-2 参考文献文字列（架空）

/negative_reference_XXXX_pre.txt

当該ファイルは、予備実験で使用した参考文献文字列（架空）を各行に記載したテキストファイルである. テキストファイル名の XXXX の取り扱いは表 1 と同様である.

▼ 5 データ/5-1 予備実験用データ/5-1-3 論文タイトル一覧

参考文献文字列（架空）に含まれる論文タイトルは、参考文献文字列（実在）に含まれる論文タイトルを生成 AI が表現の変換を行なったものである. 変換元となった論文タイトルを pre_experiment_titles.txt に記載し、生成 AI による変換後の論文タイトル

を llm_create_titles_2.txt に記載している.

▼ 5 データ/5-2 評価実験用データ/5-2-1 参考文献文字列（実在）/doi_list.txt

当該ファイルは、評価実験で使用した参考文献文字列（実在）に対する、データベース上の該当する論文の DOI を各行に記載したテキストファイルである.

▼ 5 データ/5-2 評価実験用データ/5-2-1 参考文献文字列（実在）

/positive_reference_XXXX_eval.txt

当該ファイルは、評価実験で使用した参考文献文字列（実在）を各行に記載したテキストファイルである. テキストファイル名の XXXX の取り扱いは表 1 と同様である.

▼ 5 データ/5-2 評価実験用データ/5-2-1 参考文献文字列（実在）

/positive_reference_real.txt

当該ファイルは、**本研究で使用しなかった没データ**である. 研究時、本研究で使用している参考文献文字列は全て人工的に作成したものであることから、実際に書かれてある参考文献文字列を使用した評価実験を行うべきだと考えていた. そこで、実際に書かれてある参考文献文字列を収集しようとしたのだが、当該参考文献文字列が指す論文のデータベース登録の判定、十分な数の収集などに苦戦したため断念した. なお、データベース登録の判定に誤りが含まれるため、**当該ファイルは使用するべきではない.**

▼ 5 データ/5-2 評価実験用データ/5-2-1 参考文献文字列（実在）

/real_reference_doi_list.txt

“5 データ /5-2 評価実験用データ /5-2-1 参考文献文字列（実在）
/positive_reference_real.txt” と同様、**没データであり、当該ファイルは使用するべきではない.**

▼ 5 データ/5-2 評価実験用データ/5-2-2 参考文献文字列（架空）

`/negative_reference_XXXX_eval.txt`

当該ファイルは、評価実験で使用した参考文献文字列（架空）を各行に記載したテキストファイルである。テキストファイル名の XXXX の取り扱いは表 1 と同様である。

▼ 5 データ/5-2 評価実験用データ/5-2-2 参考文献文字列（架空）

`/negative_reference_real.txt`

“5 データ /5-2 評価実験用データ /5-2-1 参考文献文字列（実在）
`/positive_reference_real.txt`” と同様、**没データであり、当該ファイルは使用するべきではない。**

▼ 5 データ/5-2 評価実験用データ/5-2-3 論文タイトル一覧

“5 データ/5-1 予備実験用データ/5-1-3 論文タイトル一覧” と同様。

▼ 5 データ/5-3 日本学術会議協力学術研究団体/

`scj_registered_AcademicSocieties.txt`

参考文献文字列（実在）は、JaLC の論文メタデータから書誌要素（著者名・論文タイトルなど）を抽出し、学会の引用スタイルに沿って組み立てることで作成している。本研究では、書誌情報を抽出する論文に条件を設定しており、その一つが「学会名が日本学術会議協力学術研究団体」である。当該ファイルには、日本学術会議協力学術研究団体を記載している。

▼ 5 データ/5-4 Apache Solr_動作テスト用データ

当該フォルダには、Apache Solr へのデータ登録後、動作確認のために使用した参考文献文字列を格納している。（予備実験および評価実験では使用していない。）人工知

能学会論文誌 18 巻 4 号に掲載されている論文から、日本語の参考文献文字列を抽出している(jsai_reference.txt)。その後、各参考文献文字列が指す文献によって分類している。(jsai_reference_book.txt, jsai_reference_others.txt, jsai_reference_paper.txt, jsai_reference_url.txt)